

Tarea 1: Descripción y Análisis Exploratorio de Datos

Transformación Box–Cox

Equipo: EAB Model

14 de septiembre de 2026

Parte I. Descripción y Análisis Exploratorio de Datos

Prestigio de la Ocupación en Canadá (Censo 1971)

1. Análisis exploratorio

El conjunto de datos contiene 102 ocupaciones canadienses, descritas por 7 variables: educación y ocupación promedio, ingreso promedio, porcentaje de mujeres, calificación de prestigio, código de censo y tipo de ocupación.

Cuadro 1: Estadísticos descriptivos de las variables cuantitativas continuas.

Variable	Media	Mediana	Desv. Est.	Mín.	Máx.
Educación (años)	10.74	10.54	2.73	6.38	15.97
Ingreso (\$)	6798	5930	4246	611	25880
Mujeres (%)	28.98	13.60	31.72	0.00	97.51
Prestigio	46.83	43.60	17.20	14.80	87.20

Cuadro 2: Frecuencias de la variable `tipo`.

Categoría	Frecuencia	Porcentaje
Obrero (bc)	44	43.1 %
Profesional (prof)	31	30.4 %
Oficinista (wc)	23	22.5 %
Sin clasificar (NA)	4	3.9 %

El EDA mostró detalles relevantes. Primero, la variable `tipo` tiene 4 valores faltantes (Athletes, Newsboys, Babysitters, Farmers), ocupaciones que no encajan en ninguna de las tres categorías del esquema Pineo-Porter. Segundo, la variable `mujeres` está fuertemente polarizada, con una alta concentración de ocupaciones cerca de 0 % y cerca de 100 % de participación femenina, reflejando la marcada segregación ocupacional por género en 1971. Tercero, se identificaron dos observaciones casi idénticas, `Slaughterers.1` y `Slaughterers.2`, con el mismo código de censo y los mismos valores de educación, ingreso y porcentaje de mujeres, pero con prestigio distinto (25.2 vs. 34.8) — probablemente corresponden a la misma ocupación evaluada en dos momentos o grupos distintos del estudio original. Finalmente, aunque el rango

de ingreso (de 611 a 25,879) no es raro de ver, la media (6798) está considerablemente por encima de la mediana (5930) debido a un valor extremo en el percentil 100; para fines descriptivos, la mediana sería una medida de tendencia central más robusta, aunque no hay justificación para excluir el outlier del análisis.

2. Clasificación de variables

Cuadro 3: Clasificación de las variables del conjunto de datos.

Variable	Clasificación
Ocupación	Cualitativa (nominal) — identificador único por observación
Educación	Cuantitativa continua — nivel educativo promedio
Ingreso	Cuantitativa continua — ingreso promedio
Mujeres	Cuantitativa continua — porcentaje de mujeres
Prestigio	Cuantitativa continua — calificación de prestigio
Censo	Cualitativa (nominal) — código de la ocupación en el censo
Tipo	Cualitativa (nominal) — obrero / profesional / oficinista

Educación, ingreso, mujeres y prestigio son cuantitativas continuas, ya que son promedios o porcentajes que pueden tomar cualquier valor real dentro de un rango (aunque ingreso se observe en números enteros, es un promedio, no una medición individual). Censo y ocupación, aunque se ven como número y texto respectivamente, son etiquetas identificadoras, no magnitudes — son cualitativas nominales, al igual que tipo. No hay ninguna variable cuantitativa discreta en este conjunto de datos.

3. Prestigio vs. nivel educativo




Figura 1: Prestigio vs. nivel educativo.

Se identifica una relación positiva y fuerte entre el nivel educativo y el prestigio de la ocupación (coeficiente de correlación de Pearson $r = 0.8502$, cercano a 1). La Figura 1 confirma esta tendencia: a mayor nivel educativo promedio, mayor prestigio en promedio, aunque con cierta dispersión alrededor de la tendencia (ocupaciones con niveles educativos similares pueden tener prestigios distintos).

Parte II. Transformación Box–Cox

Consumo de electricidad vs. consumo de agua

a. Datos originales




Figura 2: Consumo de agua vs. consumo eléctrico.

Los datos muestran una tendencia aproximadamente lineal entre ambas variables, con una relación positiva: a mayor consumo eléctrico, mayor consumo de agua. No obstante, la dispersión de los puntos alrededor de esta tendencia no es constante — conforme aumenta el consumo eléctrico, la variabilidad del consumo de agua también aumenta, lo cual sugiere un problema de heterocedasticidad que deberá confirmarse mediante el análisis de residuales.

b. Regresión lineal simple sobre los datos sin transformar

Se ajusta el modelo $y_i = \beta_0 + \beta_1 x_i + \varepsilon_i$, con $\varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$, mediante mínimos cuadrados: $\hat{\beta} = (X'X)^{-1}X'y$.

Cuadro 4: Modelo de regresión lineal simple, datos sin transformar.

Parámetro	Estimador	Error Est.	t	p
β_0	2.8841	0.707	4.081	< 0.001
β_1	1.3023	0.121	10.805	< 0.001

Con $R^2 = 0.709$. Ambos coeficientes son altamente significativos.

c. Análisis de residuales

Los residuales son $e_i = y_i - \hat{y}_i$. El modelo asume homocedasticidad, $\text{Var}(\varepsilon_i | x_i) = \sigma^2$ constante. La prueba de Breusch-Pagan contrasta H_0 : varianza constante; la prueba de Jarque-Bera contrasta H_0 : normalidad de los residuales.




Figura 3: Diagnóstico de residuales del modelo sin transformar. (a) Residuales vs. valores ajustados; (b) QQ-plot de residuales.

En la Figura 3(a) se observa heterocedasticidad: conforme aumentan los valores ajustados, aumenta la varianza de los residuales, formando un patrón de abanico (Breusch-Pagan: estadístico= 3.835, $p = 0.0502$, en el límite de significancia). En la Figura 3(b) se observan dos outliers que impiden la normalidad en las colas (Jarque-Bera: $p = 0.000174$). En conjunto, estas gráficas muestran que el modelo lineal sin transformar no es adecuado.

d. Transformación Box-Cox

La transformación Box-Cox normalizada es

$$y^{(\lambda)} = \begin{cases} \frac{y^\lambda - 1}{\lambda \dot{y}^{\lambda-1}} & \lambda \neq 0 \\ \dot{y} \ln(y) & \lambda = 0 \end{cases}, \quad \dot{y} = \left(\prod_{i=1}^n y_i \right)^{1/n}$$

Se ajusta $y^{(\lambda)} = \beta_0 + \beta_1 x + \varepsilon$ para distintos λ , y se elige $\hat{\lambda} = \arg \min_{\lambda} SC_{\text{Res}}(\lambda)$. El intervalo aproximado del $100(1 - \alpha) \%$ de confianza para λ es $\{\lambda : SC_{\text{Res}}(\lambda) \leq SC^*\}$, con

$$SC^* = SC_{\text{Res}}(\hat{\lambda}) \left(1 + \frac{t_{(1-\alpha/2, \nu)}^2}{\nu} \right), \quad \nu = n - 2$$




Figura 4: $SC_{\text{Res}}(\lambda)$ de la transformación Box-Cox.

Se obtuvo $\hat{\lambda} = -0.147$, con un intervalo de confianza del 90 % de $(-0.556, 0.258)$. Como $\lambda = 0$ también está dentro de este intervalo ($SC_{\text{Res}}(0) = 190.35$ vs. $SC_{\text{Res}}(\hat{\lambda}) = 188.93$, ambos muy por debajo del umbral $SC^* = 199.998$), y es más simple e interpretable que -0.147 , se utiliza $\lambda = 0$ (transformación logarítmica) para los siguientes incisos, sin que esto implique una pérdida de ajuste relevante.

e. Gráfica de la respuesta transformada




Figura 5: $y^{(\lambda)}$ vs. x , con $\lambda = 0$.

La Figura 5 muestra que la transformación corrigió el problema de varianza creciente conforme aumenta x observado en la Figura 2. Ahora la dispersión de los puntos se mantiene aproximadamente constante en todo el rango de x , tanto para valores chicos como para valores grandes.

f. Modelo transformado y validación

Con $\lambda = 0$ fijo se ajusta $y_i^{(0)} = \beta_0 + \beta_1 x_i + \varepsilon_i$, con $y_i^{(0)} = \hat{y} \ln(y_i)$.

Cuadro 5: Modelo de regresión sobre la respuesta transformada ($\lambda = 0$).

Parámetro	Estimador	Error Est.	t	p
β_0	12.1300	0.572	21.200	< 0.001
β_1	1.2153	0.098	12.454	< 0.001

Con $R^2 = 0.764$ (mayor al 0.709 del modelo sin transformar).




Figura 6: Diagnóstico de residuales del modelo transformado. (a) Residuales vs. valores ajustados; (b) QQ-plot de residuales.

La Figura 6(a) muestra una mejora notable en la homocedasticidad respecto a la Figura 3(a): la razón entre la dispersión de residuales en la mitad alta y la mitad baja de los valores ajustados se redujo de 2.6 a 1.8 veces, y la prueba de Breusch-Pagan pasó de un p-valor de 0.0502 a 0.2112, sin evidencia de heterocedasticidad en el modelo transformado. La normalidad también mejoró (Jarque-Bera: p de 0.000174 a 0.0203), aunque sigue sin cumplirse al 5 %.

Cuadro 6: Observaciones con mayor residual absoluto.

Obs.	x (elec.)	y (agua)	Residual sin transf.	Residual transf.
33	6.56	4.86	-6.568	-6.593
39	7.81	21.73	8.680	4.689

Esto se explica por dos observaciones atípicas, presentes en ambos modelos. El residual de la observación 39 mejoró considerablemente (de 8.68 a 4.69), mientras que el de la observación 33 prácticamente no cambió, ya que corresponde a un dato genuinamente atípico que la transformación no puede corregir. En conjunto, la transformación Box-Cox mejoró sustancialmente el modelo, sin resolver por completo el problema de normalidad.

g. Intervalo de confianza del 90 % para el consumo medio de agua

El intervalo de confianza del $100(1 - \alpha) \%$ para la respuesta media $E[Y^{(0)} | x_0]$ es

$$\hat{y}_0^{(0)} \pm t_{(1-\alpha/2, n-2)} \cdot s \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}$$

Con $x_0 = 7.57$ y $\alpha = 0.10$. El intervalo se calcula en la escala transformada y se invierte con $y = \exp(y^{(0)}/\hat{y})$, válido porque la transformación es monótona.




Figura 7: Intervalo de confianza del 90 % para el consumo medio de agua, escala original.

Con 90 % de confianza, el consumo medio de agua esperado para un consumo eléctrico de 7.57 kw/hr está entre **11.284 y 13.050 m³/mes** (estimación puntual: 12.135 m³/mes).

h. Intervalo de predicción del 95 % para el consumo de agua

El intervalo de predicción para una observación individual nueva $Y_{\text{nuevo}} \mid x_0$ es

$$\hat{y}_0^{(0)} \pm t_{(1-\alpha/2, n-2)} \cdot s \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}$$

Con $x_0 = 5.1$ y $\alpha = 0.05$. La diferencia con la fórmula del inciso (g) es el “+1” dentro de la raíz: incorpora la varianza de una observación individual alrededor de la recta, además de la incertidumbre de estimar la recta misma.




Figura 8: Intervalo de predicción del 95 % para una observación individual, escala original.

Con 95 % de confianza, el consumo de agua de una observación individual con consumo eléctrico de 5.1 kw/hr estará entre **5.321 y 13.709 m³/mes** (estimación puntual: 8.541 m³/mes). La Figura 8 es mucho más ancha que la Figura 7 porque esta última es un intervalo de predicción, con varianza más alta por tratarse de un punto individual, mientras que la Figura 7 es un intervalo de confianza para el consumo “medio”.